




人工智能




沙瀛

信息学院
2020.4



人工智能

人工神经网络概述

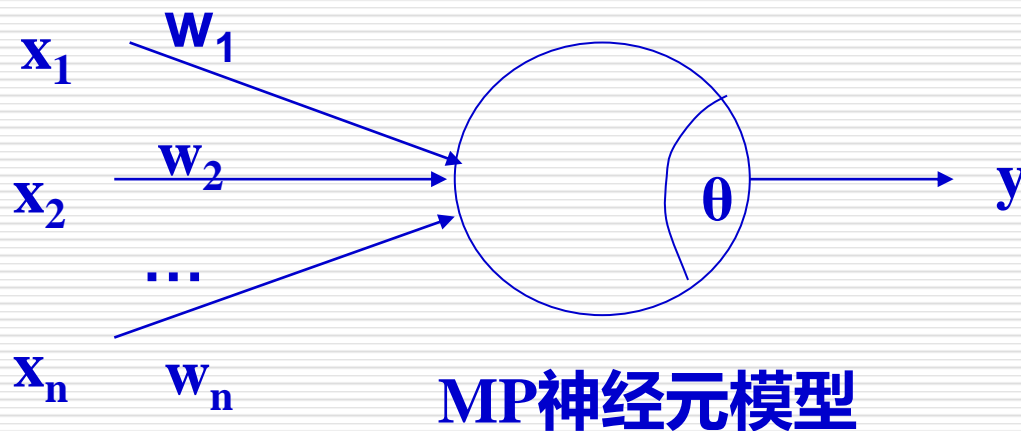


内容

- 人工神经网络基础
 - 人工神经网络的互联结构
 - 前馈网络
 - 反馈网络
 - 人工神经网络的典型模型
 - 感知器模型
 - **BP**网络模型
 - **Hopfield**网络模型
 - 深度卷积神经网络
-

一、人工神经网络简介

人工神经元的结构



MP模型是于1943年提出的一种将神经元看作二进制阈值元件的简单模型。

人工神经元是一个具有多输入，单输出的非线性器件。

其输入为： $\sum_{i=1}^n w_i x_i$

其输出为： $y = f(\sigma) = f(\sum_{i=1}^n w_i x_i - \theta)$


一、人工神经网络简介

常用的人工神经元模型

根据功能函数的不同，可得不同的神经元模型。

阈值型(Threshold)

这种模型的神经元没有内部状态，作用函数 f 是一个阶跃函数，他表示激活值 σ 和输出之间的关系。




一、人工神经网络简介

常用的人工神经元模型

分段线性强饱和型(Linear Saturation)

这种模型又称为伪线性，其输入/输出之间在一定范围内满足线性关系，一直延续到输出为最大值1为止。但当达到最大值后，输出就不再增。




一、人工神经网络简介

常用的人工神经元模型

S型(Sigmoid)

这是一种连续的神经元模型，其输入输出特性常用指数、对数或双曲正切等S型函数表示。它反映的是神经元的饱和特性。




一、人工神经网络简介

常用的人工神经元模型

子阈累积型(Subthreshold Summation)

也是一个非线性函数，当产生的激活值超过T值时，该神经元被激活产生个反响。在线性范围内，系统的反响是线性的。





一、人工神经网络简介


人工神经网络及其分类

人工神经网络的分类

按拓扑结构 { 前馈网络
反馈网络

按学习方法 { 有导师指导
无导师指导

按网络性能 { 连续型网络
离散型网络



二、人工神经网络的互联结构

人工神经网络的互连结构（或称拓扑结构）是指单个神经元之间的连接模式，它是构造神经网络的基础，也是神经网络诱发偏差的主要来源。从互连结构的角度：

仅含输入层和输出层，
且只有输出层的神经元
是可计算节点

$$y_j = f\left(\sum_{i=1}^n w_{ij}x_i - \theta_j\right) \quad j = 1, 2, \dots, m$$


除拥有输入、输出层外，
还至少含有一个、或更
多个隐含层的前向网络

单层前馈
网络

多层前馈
网络

1. 前馈网络

（只包含前向联
结）



二、人工神经网络的互联结构

2. 反馈网络


(可含有反馈联结)

单层反馈
网络

多层反馈
网络

指不拥有隐含层的
反馈网络

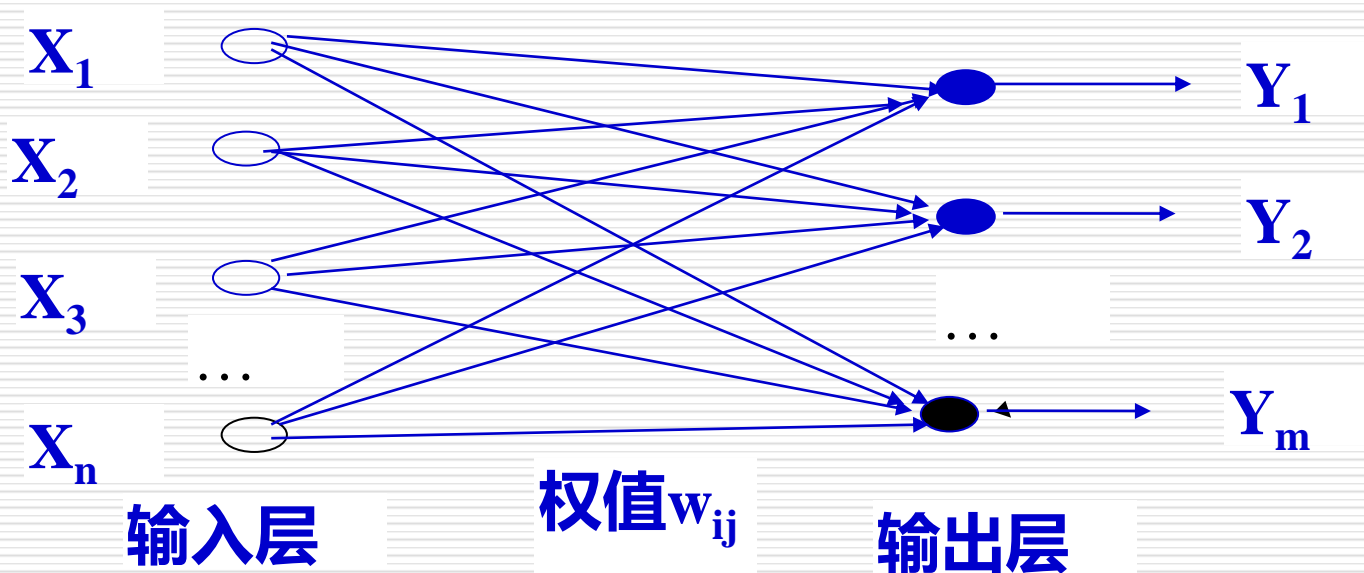
指拥有隐含层的
反馈网络




1. 前馈网络

单层前馈网络(1/3)

单层前馈网络是指那种只拥有单层计算节点的前向网络。它仅含有输入层和输出层，且只有输出层的神经元是可计算节点，如下图所示



单层前馈网络结构



1. 前馈网络

单层前馈网络(2/3)


若假设各神经元的阈值分别是 θ_j , $j=1,2,\dots,m$, 则各神经元的输出 y_j , $j=1,2,\dots,m$ 分别为:

$$y_j = f\left(\sum_{i=1}^n w_{ij}x_i - \theta_j\right) \quad j = 1, 2, \dots, m$$

其中, 由所有连接权值 w_{ij} 构成的连接权值矩阵 W 为:

$$W = \begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1m} \\ w_{21} & w_{22} & \cdots & w_{2m} \\ \vdots & \vdots & & \vdots \\ w_{n1} & w_{n2} & \cdots & w_{nm} \end{pmatrix}$$

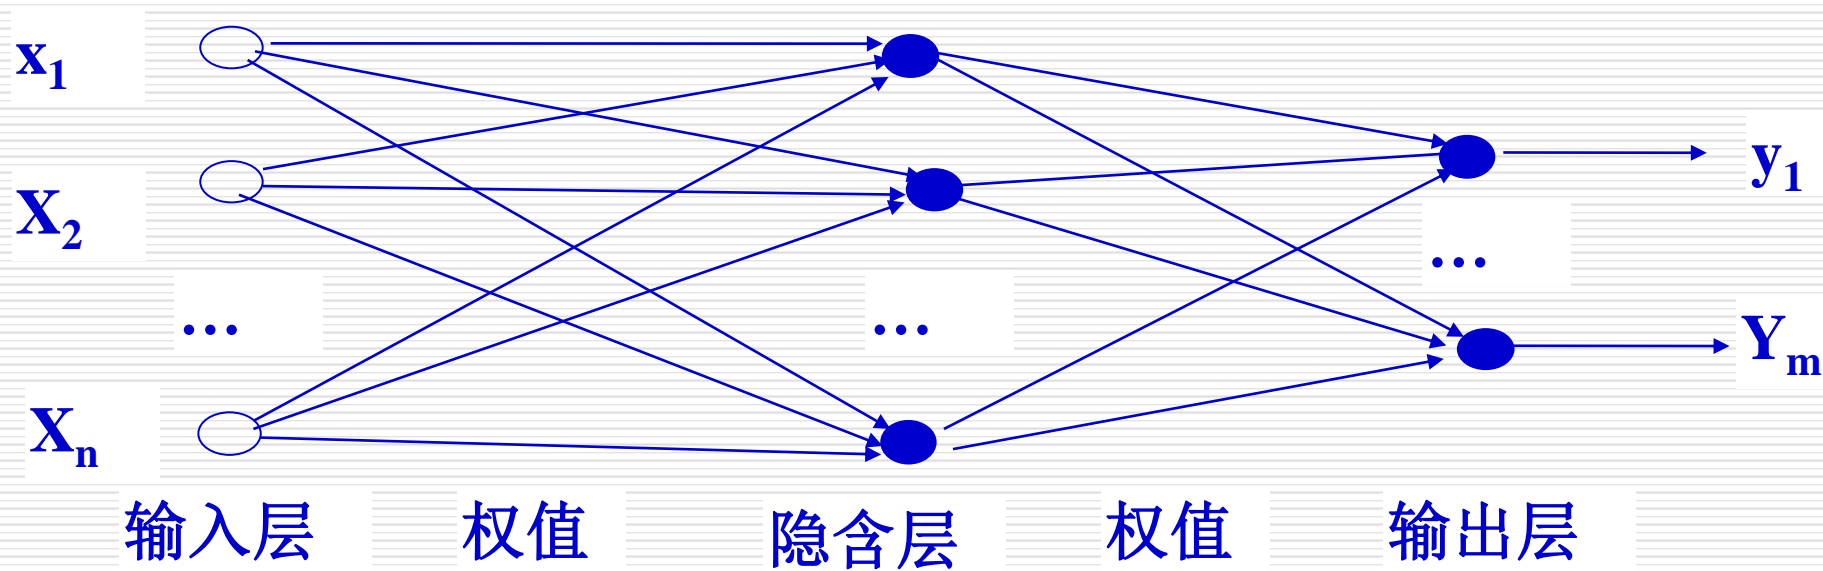
在实际应用中, 该矩阵是通过大量的训练示例学习而形成的。



1. 前馈网络

多层前馈网络(3/3)


多层前馈网络是指那种除拥有输入、输出层外，还至少含有一个、或更多个隐含层的前馈网络。





1. 前馈网络

- 多层前馈网络的输入层的输出向量是第一隐含层的输入信号，而第一隐含层的输出则是第二隐含层的输入信号，以此类推，直到输出层。
 - 多层前馈网络的典型代表是**BP**网络。
-



2. 反馈神经网络


反馈网络是指允许采用反馈联结方式所形成的神经网络。所谓反馈联结方式是指一个神经元的输出可以被反馈至同层或前层的神经元。

反馈网络的典型例子是后面将要介绍的Hopfield网络



2. 反馈神经网络

- 反馈网络和前向网络不同：
 - 前向网络属于非循环连接模式，它的每个神经元的输入都没有包含该神经元先前的输出，因此不具有“短期记忆”的性质。
 - 反馈网络则不同，它的每个神经元的输入都有可能包含有该神经元先前输出的反馈信息，即一个神经元的输出是由该神经元当前的输入和先前的输出这两者来决定的，这就有点类似于人类的“短期记忆”的性质。
-




三、人工神经网络的典型模型

重点讨论

1. 感知器 (Perceptron) 模型
 2. 前向传播 (BP) 模型
 3. 反馈网络 (Hopfield) 模型
-

1. 感知器模型

单层 感知器(1/7)



感知器的拓扑结构是一种分层前向网络。它包括：单层感知器和多层感知器。


单层感知器是一种只具有单层可调节连接权值神经元的前向网络，这些神经元构成了单层感知器的输出层，是感知器的可计算节点。

在单层感知器中，每个可计算节点都是一个线性阈值神经元。当输入信息的加权和大于或等于阈值时，输出为1，否则输出为0或-1。

单层感知器的输出层的每个神经元都只有一个输出，且该输出仅与本神经元的输入及联接权值有关，而与其他神经元无关。

1. 感知器模型

单层感知器(2/7)



输入向量为 $X=(x_1, x_2, \dots, x_n)$; 输出向量为 $Y=(y_1, y_2, \dots, y_m)$;

输入层各个输入到相应神经元的连接权值分别是 w_{ij} , $i=1, 2, \dots, n$, $j=1, 2, \dots, m$ 。

1. 感知器模型

单层感知器(2/7)


若假设各神经元的阈值分别是 θ_j , $j=1,2,\dots,m$, 则各神经元的输出 y_j , $j=1,2,\dots,m$ 分别为

$$y_j = f\left(\sum_{i=1}^n w_{ij}x_i - \theta_j\right) \quad j = 1, 2, \dots, m$$

其中, 由所有连接权值 w_{ji} 构成的连接权值矩阵 W 为:

$$W = \begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1m} \\ w_{21} & w_{22} & \cdots & w_{2m} \\ \vdots & \vdots & & \vdots \\ w_{n1} & w_{n2} & \cdots & w_{nm} \end{pmatrix}$$

在实际应用中, 该矩阵是通过大量的训练示例学习而形成的



1.感知器模型


单层感知器(3/7)

使用感知器的主要目的是为了对外部输入进行分类。

如果外部输入是线性可分的（指存在一个超平面可以将它们分开），则单层感知器一定能够把它划分为两类。其判别超平面由如下判别式确定：

$$\sum_{i=1}^n w_{ij} x_i - \theta_j = 0 \quad j = 1, 2, \dots, m$$

单层感知器可以很好地实现“与”、“或”、“非”运算，但却不能解决“异或”问题。




1. 感知器模型


单层感知器(4/7)

例1 “与”运算 ($x_1 \wedge x_2$)

| 输入 | | 输出 | 超平面 | 阈值条件 |
|-------|-------|------------------|--------------------------------------|-------------------------|
| x_1 | x_2 | $x_1 \wedge x_2$ | $w_1 * x_1 + w_2 * x_2 - \theta = 0$ | |
| 0 | 0 | 0 | $w_1 * 0 + w_2 * 0 - \theta < 0$ | $\theta > 0$ |
| 0 | 1 | 0 | $w_1 * 0 + w_2 * 1 - \theta < 0$ | $\theta > w_2$ |
| 1 | 0 | 0 | $w_1 * 1 + w_2 * 0 - \theta < 0$ | $\theta > w_1$ |
| 1 | 1 | 1 | $w_1 * 1 + w_2 * 1 - \theta \geq 0$ | $\theta \leq w_1 + w_2$ |

可以证明此表有解，例如取
 $w_1=1$, $w_2=1$, $\theta=1.5$, 其分类结
果如右图所示。






1. 感知器模型


单层感知器(5/7)

例2 “或”运算 ($x_1 \vee x_2$)

| 输入 | | 输出 | 超平面 | 阈值条件 |
|-------|-------|----------------|--------------------------------------|-------------------------|
| x_1 | x_2 | $x_1 \vee x_2$ | $w_1 * x_1 + w_2 * x_2 - \theta = 0$ | |
| 0 | 0 | 0 | $w_1 * 0 + w_2 * 0 - \theta < 0$ | $\theta > 0$ |
| 0 | 1 | 1 | $w_1 * 0 + w_2 * 1 - \theta \geq 0$ | $\theta \leq w_2$ |
| 1 | 0 | 1 | $w_1 * 1 + w_2 * 0 - \theta \geq 0$ | $\theta \leq w_1$ |
| 1 | 1 | 1 | $w_1 * 1 + w_2 * 1 - \theta \geq 0$ | $\theta \leq w_1 + w_2$ |

此表也有解，例如取 $w_1=1$ ， $w_2=1$ ， $\theta=0.5$ ，其分类结果如右图所示。






1. 感知器模型

单层感知器(6/7)


例3 “非”运算 ($\neg x_1$)

| 输入 | 输出 | 超平面 | 阈值条件 |
|-------|------------|---------------------------|-----------------|
| x_1 | $\neg x_1$ | $w_1 * x_1 - \theta = 0$ | |
| 0 | 1 | $w_1 * 0 - \theta \geq 0$ | $\theta \leq 0$ |
| 1 | 0 | $w_1 * 1 - \theta < 0$ | $\theta > w_1$ |

此表也有解，例如取 $w_1 = -1$ ， $\theta = -0.5$ ，其分类结果如右图所示。



非运算问题图示




1. 感知器模型

单层感知器(77)

例4 “异或”运算 ($x_1 \text{ XOR } x_2$)

| 输入 | | 输出 | 超平面 | 阈值条件 |
|-------|-------|------------------------|--------------------------------------|----------------------|
| x_1 | x_2 | $x_1 \text{ XOR } x_2$ | $w_1 * x_1 + w_2 * x_2 - \theta = 0$ | |
| 0 | 0 | 0 | $w_1 * 0 + w_2 * 0 - \theta < 0$ | $\theta > 0$ |
| 0 | 1 | 1 | $w_1 * 0 + w_2 * 1 - \theta \geq 0$ | $\theta \leq w_2$ |
| 1 | 0 | 1 | $w_1 * 1 + w_2 * 0 - \theta \geq 0$ | $\theta \leq w_1$ |
| 1 | 1 | 0 | $w_1 * 1 + w_2 * 1 - \theta < 0$ | $\theta > w_1 + w_2$ |

此表无解，即无法找到满足条件的 w_1 、 w_2 和 θ ，如右图所示。因为异或问题是一个非线性可分问题，需要用多层感知器来解决。



1. 感知器模型

多层 感知器(1/2)

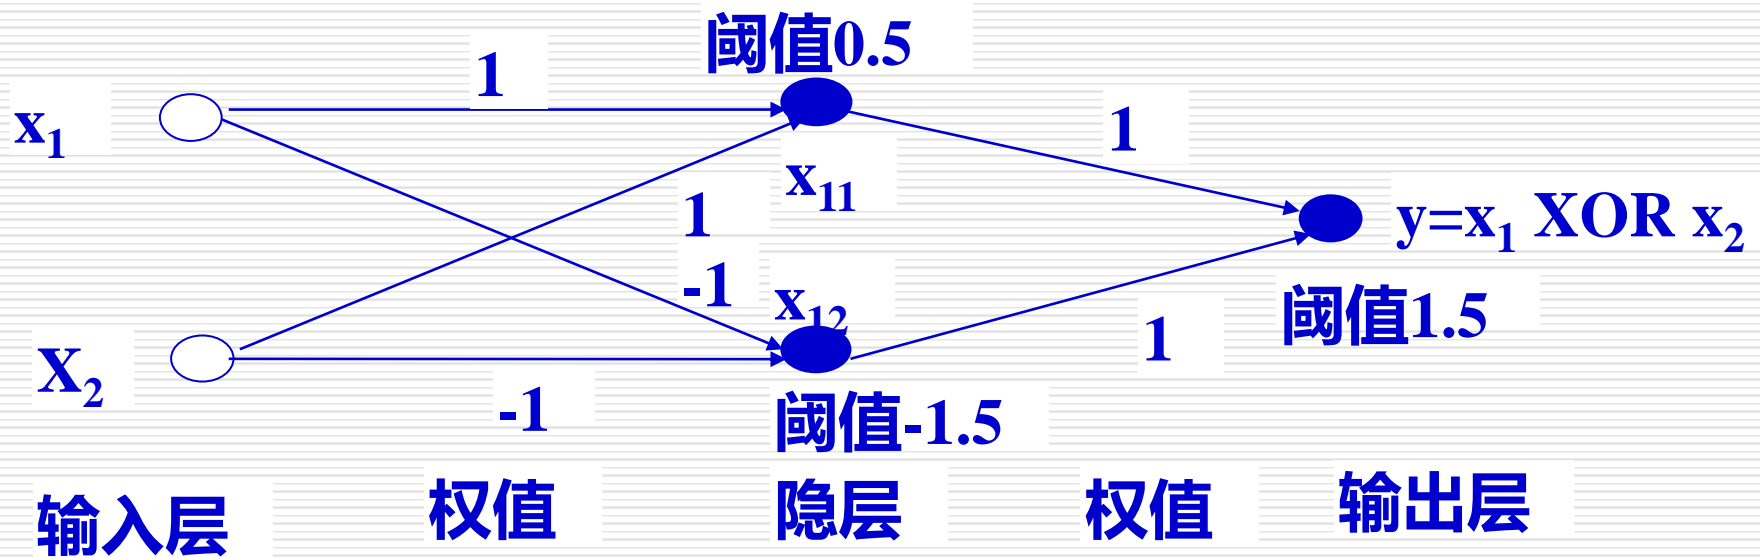
(2) 多层感知器

多层感知器是通过在单层感知器的输入、输出层之间加入一层或多层处理单元所构成的。

多层感知器的输入与输出之间是一种高度非线性的映射关系，因此，多层感知器可以实现非线性可分问题的分类。例如，对“异或”运算，用多层感知器即可解决。

1. 感知器模型

多层 感知器(2/2)



“异或”问题的多层感知器

1. 感知器模型

多层 感知器(2/2)

在图中，隐层神经元 x_{11} 所确定的直线方程为

$$1 * x_1 + 1 * x_2 - 0.5 = 0$$


它可以识别一个半平面。隐层神经元 x_{12} 所确定的直线方程为

$$1 * x_1 + 1 * x_2 - 1.5 = 0$$

它也可以识别一个半平面。

输出层神经元所确定的直线方程为

$$1 * x_{11} + 1 * x_{12} - 1.5 = 0$$

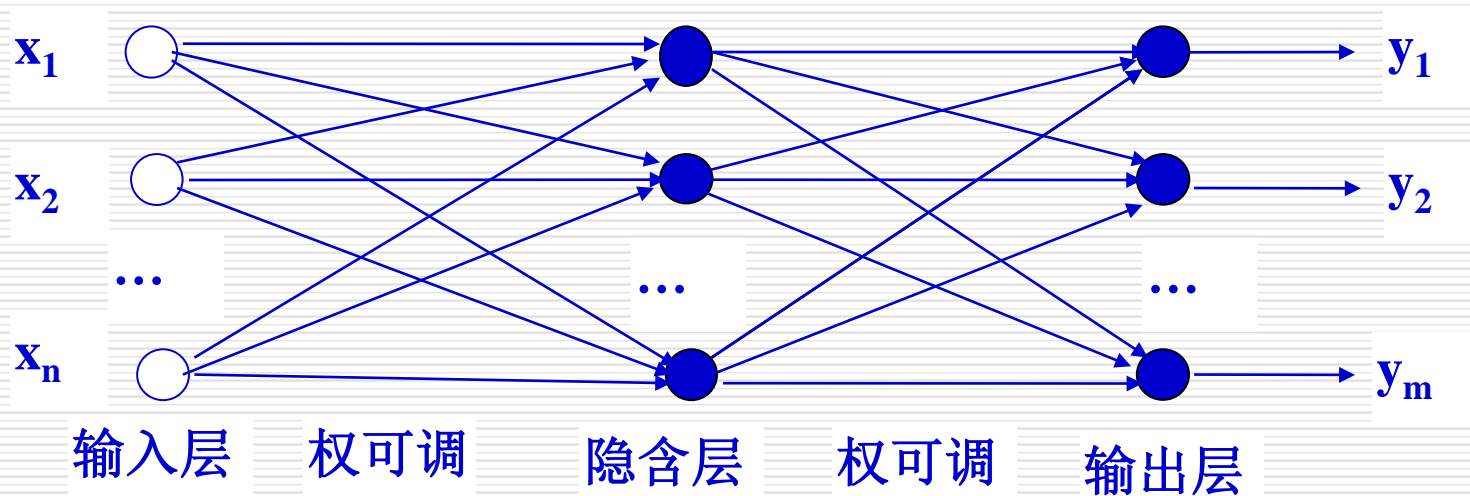


异或问题的解决

2. BP网络模型

误差反向传播(Error Back Propagation)网络通常简称为BP(Back Propagation)网络。

BP网络的网络拓扑结构是多层前向网络。在BP网络中，同层节点之间不存在相互连接，层与层之间多采用全互连方式，且各层的连接权值可调。



一个多层BP网络的结构



2. BP网络模型

第二，BP网络的学习过程是由工作信号的正向传播和误差信号的反向传播组成的。

所谓正向传播，是指输入模式经隐层到输出层，最后形成输出模式；

所谓误差反向传播，是指从输出层开始逐层将误差传到输入层，并修改各层联接权值，使误差信号为最小的过程。



3. Hopfield网络模型

离散Hopfield网络模型(1/2)

离散Hopfield网络的结构

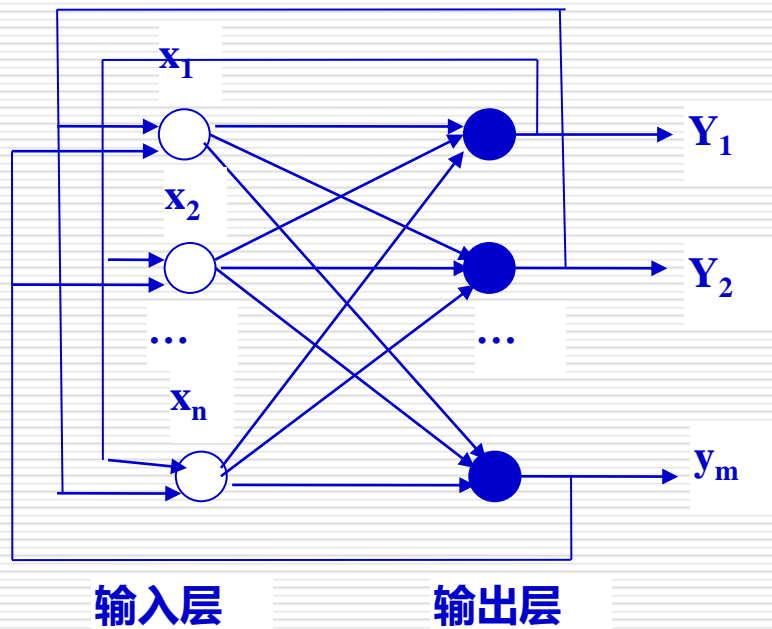
离散Hopfield网络是在非线性动力学的基础上由若干基本神经元构成的一种单层全互连网络，其任意神经元之间均有连接，并且是一种对称连接结构。


$$w_{ij} = \begin{cases} w_{ji} & \text{若 } i \neq j \\ 0 & \text{若 } i = j \end{cases}$$

由该连接权值所构成的连接矩阵是一个零对角的对称矩阵。

3. Hopfield网络模型

离散Hopfield网络模型(2/2)






3. Hopfield网络模型

在 **Hopfield**网络中，虽然神经元自身无连接，但由于每个神经元都与其他神经元相连，即每个神经元的输出都将通过突触连接权值传递给别的神经元，同时每个神经元又都接受其他神经元传来的信息，这样对每个神经元来说，其输出经过其他神经元后又有可能反馈给自己，因此**Hopfield**网络是一种反馈神经网络

四、深度卷积神经网络

深度卷积神经网络 (Deep Neural Network, DCNN)

深度卷积神经网络的学习过程即是对卷积神经网络的训练过程，它由计算信号的正向传播过程和误差的反向传播过程所组成。

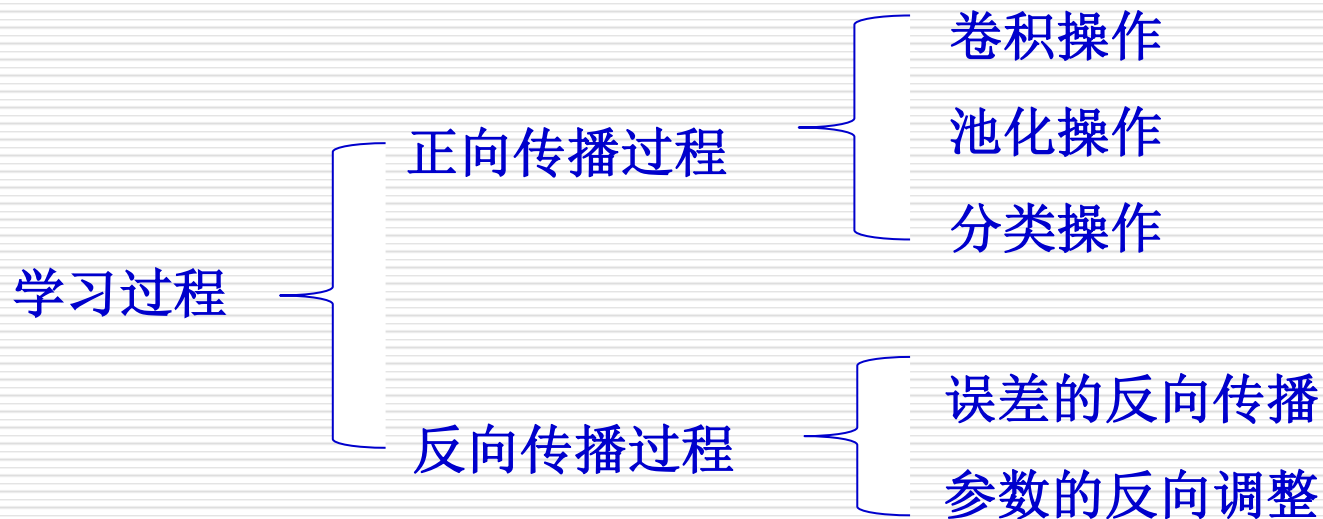


LeNet5的基本结构



深度卷积神经网络学习

卷积神经网络的学习过程就是对卷积神经网络的训练过程，它由正向传播过程和反向传播过程所组成。





1. 卷积神经网络学习的正向传播过程

(1) 卷积核与卷积操作

卷积（convolution）在卷积神经网络中的主要作用是实现卷积操作，形成网络的卷积层。

卷积操作的基本过程是：针对图像的某一类特征，先构造其特征过滤器（FF），然后利用该过滤器对图像进行特征提取，得到相应特征的特征图（FM）。依此针对图像的每一类特征，重复如上操作，最后得到由所有特征图构成的卷积层。



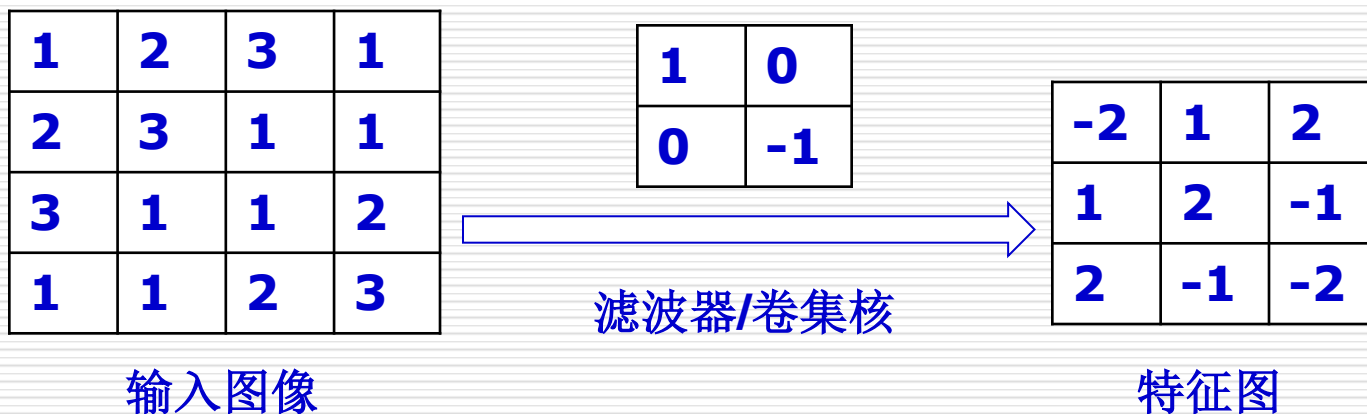
1. 卷积神经网络学习的正向传播过程

(1) 卷积核与卷积操作

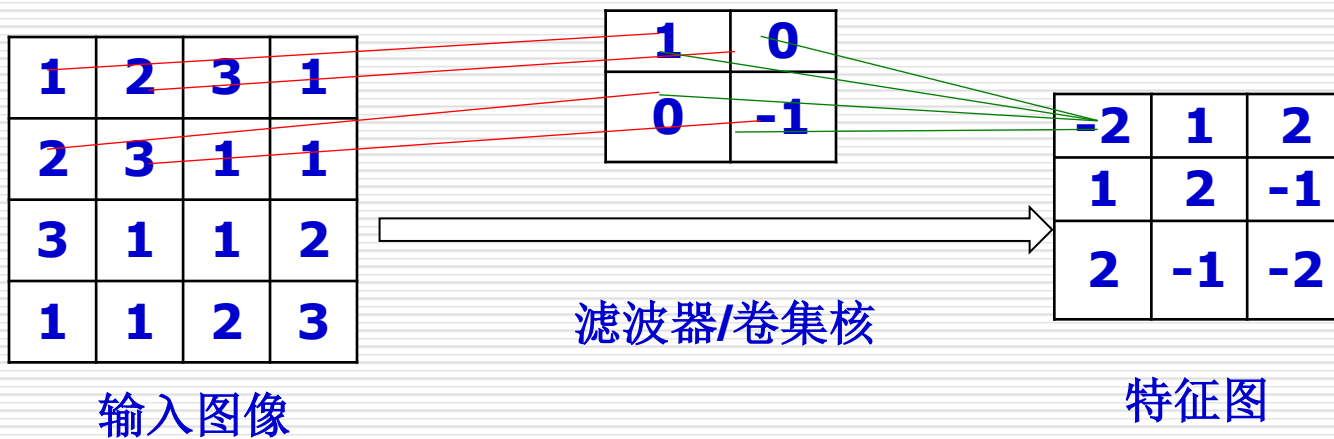
特征过滤器也称为卷积核（Coiling Kernel, CK），它实际上是由相关神经元连接权值所形成的一个权值矩阵，该矩阵的大小由卷积核的大小确定。卷积核与特征图之间具有一一对应关系，一个卷积核唯一地确定了一个特征图，而一个特征图也唯一地对应着一个卷积核。

1. 卷积神经网络学习的正向传播过程

从左上角开始移动到右下角，每次移动一步，每移动一步都要将滤波器与其在原图像中所对应位置的子图像做卷积运算，最终得到卷积后的图像，即特征图。




1. 卷积神经网络学习的正向传播过程



1. 卷积神经网络学习的正向传播过程

再如，对特征图第2行第3列的元素

$$F_{2,3} = 1 \times 1 + 1 \times 0 + 1 \times 0 + 2 \times (-1) = -1$$





1. 卷积神经网络学习的正向传播过程

(2) 池化层与池化操作

池化层（Pooling Layer）也叫子采样层（Subsample Layer）或降采样（downsampling），其主要作用是利用子采样（或降采样）对输入图像的像素进行合并，得到池化层的特征图谱。



1. 卷积神经网络学习的正向传播过程

①池化操作及基本过程

池化操作的一个重要概念是池化窗口或子采样窗口。所谓池化窗口是指池化操作所使用的一个矩形区域，池化操作利用该矩形区域实现对卷积层特征图像素的合并。

例如，一个 $8*8$ 的输入图像，若采用大小为 $2*2$ 的池化窗口对其进行池化操作，就意味着原图像上的4个像素将被合并为1个像素，原卷积层中的特征图经池化操作后将缩小为原图的 $1/4$ 。



1. 卷积神经网络学习的正向传播过程

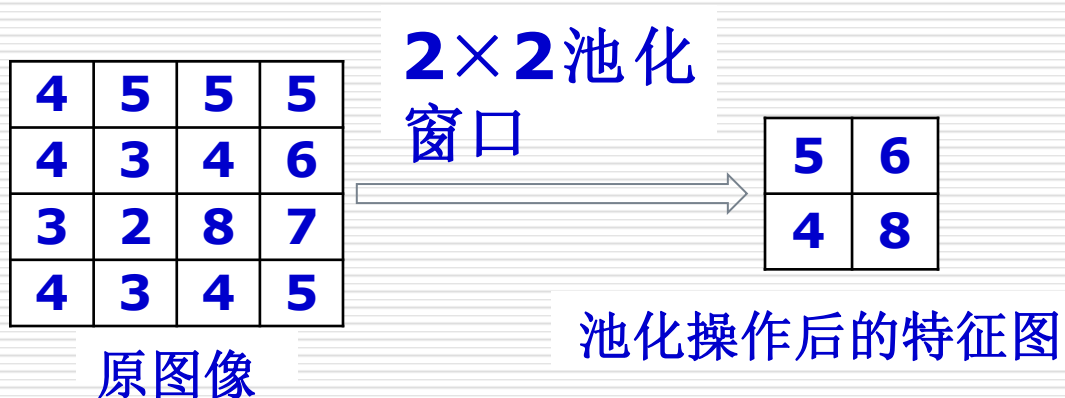
①池化操作及基本过程

池化操作的基本过程是：从特征图的左上角开始，按照池化窗口，先从左到右，然后再从上向下，不重叠地依次扫过整个图像，并同时利用子采样方法进行池化计算。

常用的池化方法有最大池化（max pooling）法、平均池化（mean pooling）法和概率矩阵池化（stochastic pooling）法等。这里主要讨论最大池化法和平均池化法。

1. 卷积神经网络学习的正向传播过程

② 最大池化法



1. 卷积神经网络学习的正向传播过程

③ 平均池化法






2. 卷积神经网络的反向传播

卷积神经网络的反向传播涉及到两个基本问题，

- 一个是误差的反向传播
- 一个是参数的反向调整


其中，前者与当前网络层的类型有关，即卷积层、池化层、全连接层的误差反向传播方法不同；后者一般通过梯度计算来实现。



3. LeNet5的基本结构

LeNet5是深度卷积神经网络的经典模型，它产生于1998年，主要用于手写体数字和字母的识别。LeNet5虽然规模较小，但其结构完整、功能齐全，很适合作为深度卷积网络学习的教学用例。

3. LeNet5的基本结构



该图中输入图像为 32×32 的黑白图片，卷积核大小为 5×5 ，各卷积层卷积核的个数分别为6、16、120种，子采样窗口大小为 2×2 。



本节结束!

